

Multitask Learning and GCN-Based Taxi Demand Prediction for a Traffic Road Network

1.摘要和背景简介

随着城市的发展，出租车成为城市中的一种重要出行方式。在智能交通研究中，准确预测出租车需求是一个热点问题，但由于其复杂的时空依赖性、动态性和不确定性，对出租车需求的预测极具挑战。为了充分利用道路交通流的全局和局部的相关性，本文提出了一种**基于图卷积网络、长短时记忆(LSTM)和多任务学习**的深度学习模型。

首先，考虑道路网络中出租车出行的空间格局分布，建立**无向图模型**；然后，利用LSTMs提取交通流的时间特征；最后，采用**多任务学习策略**对模型进行训练，以提高模型的可泛化性。

文章的创新点主要可以分为以下三点：

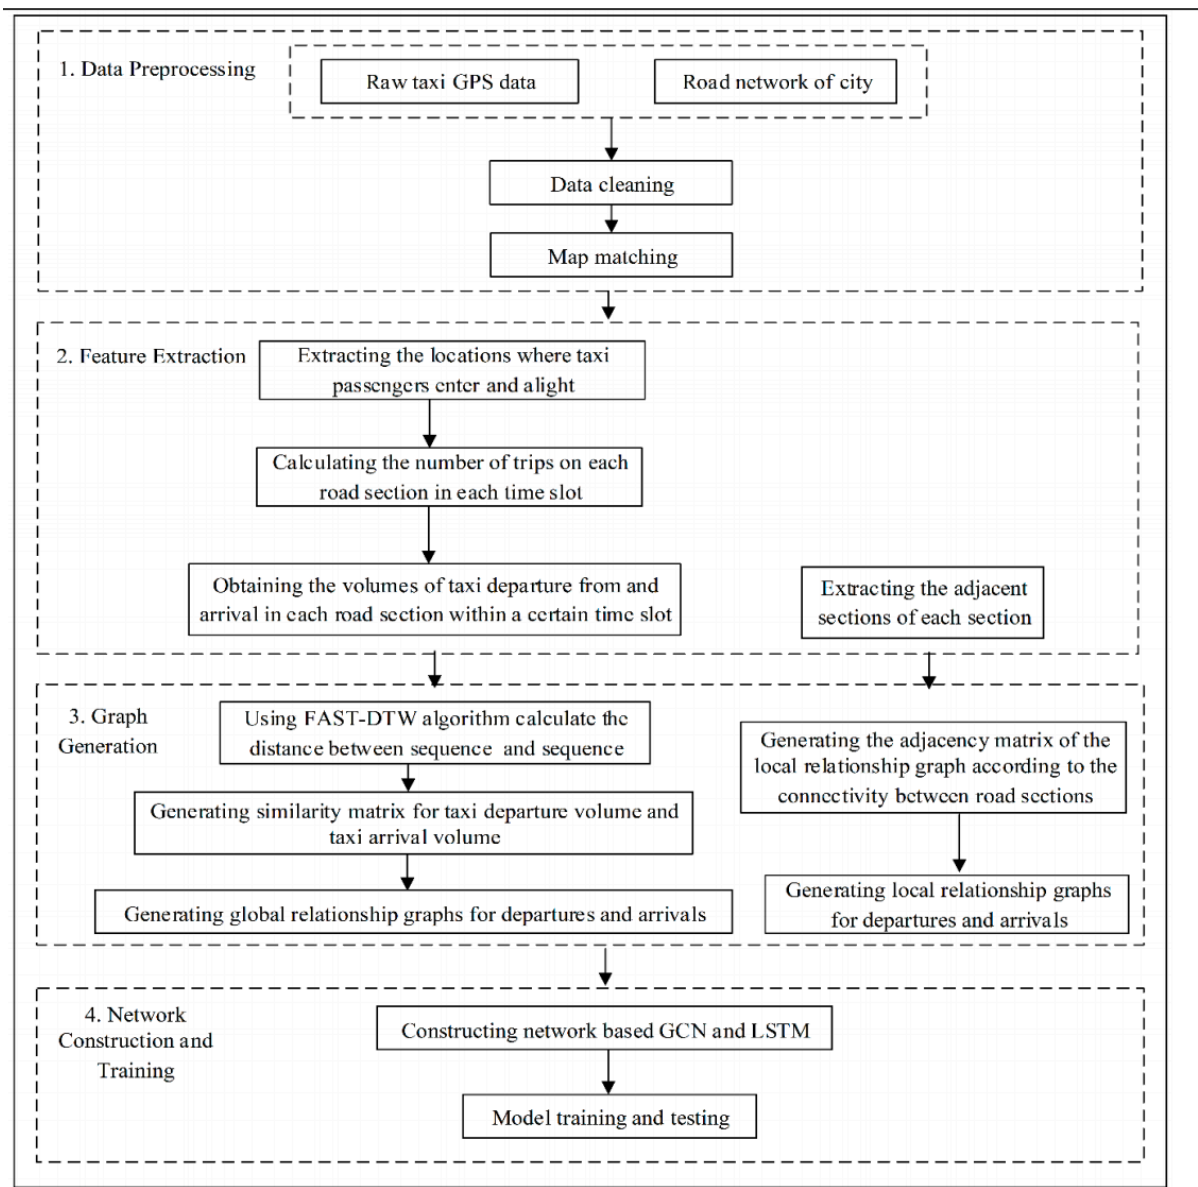
- 提出了一种基于图卷积网络预测出租车出发、到达流的模型。同时，为了实现道路水平预测，在构建交通流图时，不是采用网格区域CNN模型，而是采用路段作为节点建立图卷积网络，将出租车需求作为节点特征。
- 基于路段的局部相关性和全局相关性构建了两类交通流图。这些图被称为直接图（direct graph）和间接图（indirect graph）。直接图基于路网拓扑构造，该图综合路段间的局部连通性和空间相关性。而间接图通过考虑交通网络中所有路段之间的全局相关性，从而判断不同路段间是否连通。
- 将出发流预测任务和到达流预测任务相结合，采用多任务学习策略加快学习过程，避免过拟合，得到更一般化的结果。

2. 文章结构

- 介绍了出租车需求的研究现状，以及深度学习模型及图卷积网络（GCN）在出租车需求预测中的现状。
- 介绍了写作动机，当前大部分使用图卷积网络预测时，图的构成是基于路段的物理连接，文章认为一些非物理连接路段的进出流应该存在相似性。提出了直接图（direct graph）以及间接图（indirect graph）。
- 介绍了各个参数的含义，以及用于获取时间序列相似性，也就是计算不同时间序列相似度用到了Fast-DTW算法。
- 提出了多任务预测模型。
- 将模型应用到实际数据中，获取结果并比对。

3.本文提出的模型

本文提出模型的整体框架如图所示：



整个模型可以分为四个模块：**数据处理模块**、**特征提取模块**、**生成图模块**、**网络搭建和训练模块**。

数据处理模块：

这一部分主要是删除数据中重复和无效的部分，进一步，由于是GPS数据，存在数据偏移的问题，为了修正GPS数据，文章采用基于隐马尔可夫（Hidden Markov）的地图匹配算法，对所有轨迹进行数据匹配。

特征提取模块：

该模块主要从出租车轨迹中提取乘客上、下车的位置，并根据时间段计算各路段的出行时间。从而得到某一时段内各路段出租车发车流和到达流，这一部分数据主要用于构造非直接图。对于每个路段，根据城市路网的拓扑结构提取相邻路段，这一部分数据主要用于构造直接图。

生成图模块：

这一模块主要是借助上一模块得到的数据，生成网络所需的输入数据。在生成图的过程中，生成了四种图，分别是：**出发和到达的全局关系图和局部关系图**。具体构建方法如下：

- 1、根据路段之间的连通性（物理连接），生成**局部关系图**的邻接矩阵。
- 2、通过计算不同路段的出发/到达流序列相似性，得到**全局关系图**的邻接矩阵。

出发和到达的局部关系图其实是一致的，而全局关系图是不同的。

网络搭建和训练模块：

最后一部分是基于GCN和LSTM网络预测出发流量，并结合多任务学习策略对模型进行训练。在多任务学习中，以出租车出发流预测作为主要任务，出租车到达流预测作为相关任务，有助于提高预测精度。

网络的基本框架如下图所示：

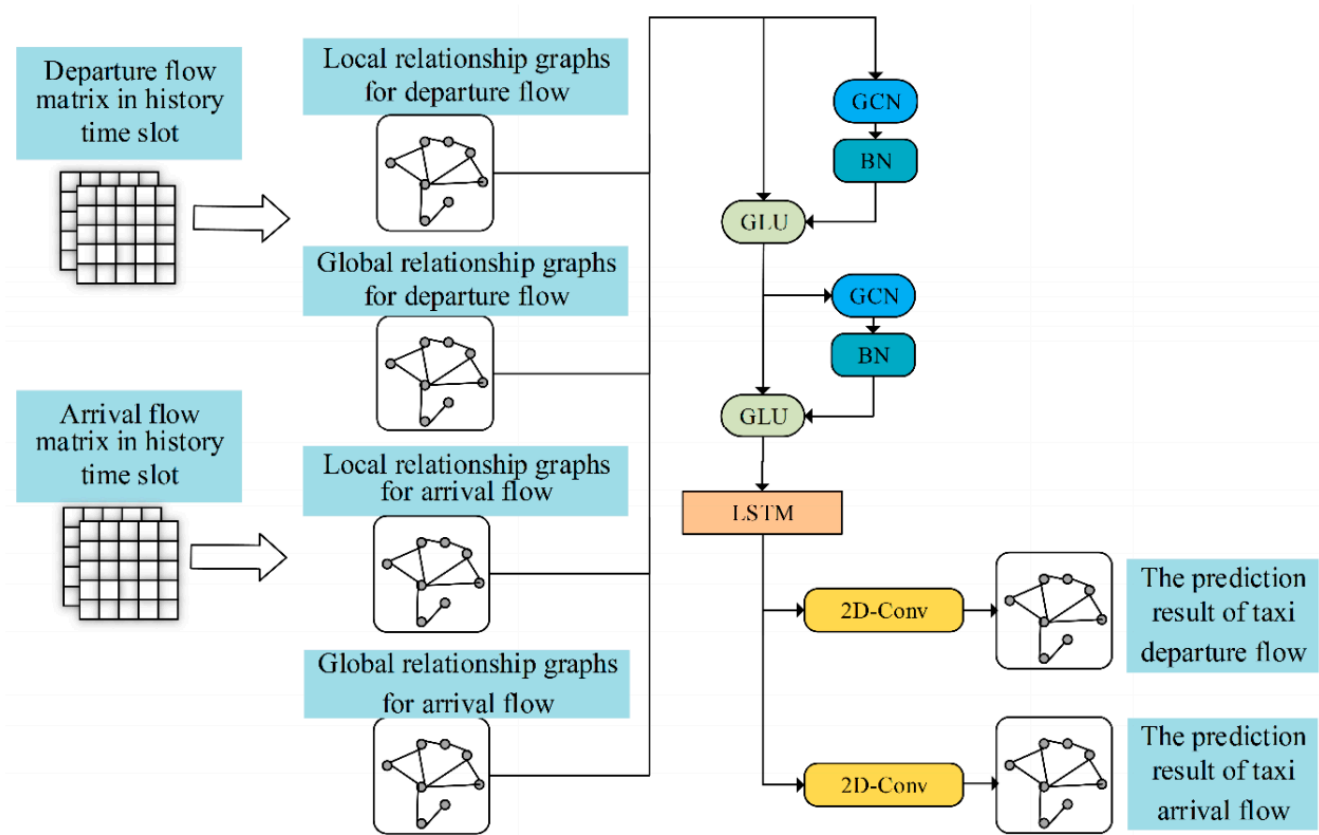


Figure 4. Multitask GCN-LSTM (MGLN) network.

整个网络也可以分为三个模块：局部和全局空间特征提取模块、时间特征提取模块、特征融合模块。接下来细说这三个模块的功能和原理。

1.局部和全局空间特征提取模块

在该模块中，将路段设置为图的节点，每个节点的特征包括该节点对应路段产生的历史到达流序列。设路段总数为R，历史时段数为K，则图的特征矩阵为X，其维度为K * R，相邻矩阵为A，其维度为R * R（对于直接图，邻接矩阵就代表其物理连接；而对于非直接图，其邻接矩阵是由路段之间的相似度构成的矩阵，相似度是通过Fast-DTW算法计算获得）。

该模块由两层GCN+GLU组成。

其中GCN层的行为如下：

$$f(\mathbf{X}, \mathbf{A}) = \text{Relu}(\hat{\mathbf{A}}\mathbf{X}\mathbf{W}), \quad (3)$$

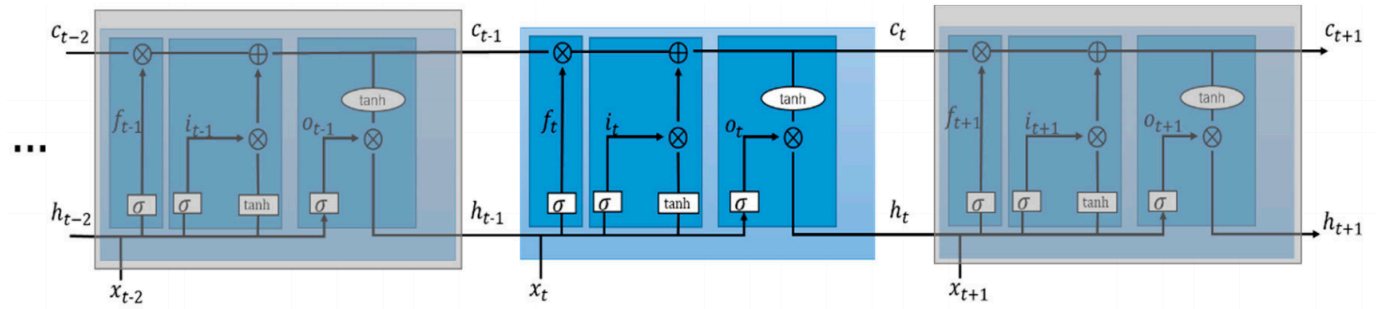
GCN+GLU+BN的行为如下：

$$f(\mathbf{X}, \mathbf{A}) = \text{BN}(\text{Relu}(\hat{\mathbf{A}}\mathbf{X}\mathbf{W})) + \sigma(\text{BN}(\text{Relu}(\hat{\mathbf{A}}\mathbf{X}\mathbf{W}))), \quad (4)$$

其中的ReLU采用的是Leaky ReLU，最终输出结果为一个 $K \times R$ 的矩阵。

2.时间特征提取模块

该模块的输入为上一模块的输出，即一个 $K \times R$ 的矩阵，输入下一个LSTM网络获取其时间特征。LSTM的具体结构图如下所示：



最终LSTM模块输出的结果是一个维度为 $1 \times R$ 的矩阵(其中R表示路段数)。

3.特征融合模块

通过不同的输入，可以获取两种变量，一种是局部路段关系图，另一种是全局路段关系图，这两种变量的维度均为 $1 \times R$ 。

将这两种变量进行拼接，得到一个 $2R$ 的矩阵，输入到二维卷积网络中（kernel_size=21, stride=1）输出一个 $1 \times R$ 的矩阵，即每个路段下一个时间步的预测结果。

由于是多任务学习，损失函数为加权求和的形式。

$$\text{上车客流的损失函数: } Loss_{in} = \|Y_{t_{in}} - \hat{Y}_{t_{in}}\|_2$$

$$\text{下车客流的损失函数: } Loss_{out} = \|Y_{t_{out}} - \hat{Y}_{t_{out}}\|_2$$

总损失函数：

为了避免过度拟合，添加了一个额外的L2正则化项，因此总损失函数可以写成：

$$Loss = \lambda_1 Loss_{in} + \lambda_2 Loss_{out} + \lambda_3 L_2$$


其中， $\lambda_i, i = 1, 2, 3$ 是超参数。

4.实验结果及分析

实验所用的数据集是来自西安的真实出租车轨迹。这些轨迹来自1万多辆出租车，覆盖了2万个路段。在每辆出租车中，GPS设备记录了车辆ID、时间戳、经纬度、车速和行驶方向。

文章选取了每周7天的数据，前六天的数据作为训练集，第七天的数据作为测试集，此外，文章选择了出发流量大于15次/天的路段，共851个路段。在现有研究中，对于发车流量较小的路段，如15个/天，不作为主干道路段，而是作为一些分支路段的代表，如与主干道相连的一个小分支。这些路段对流量预测的影响很小，在大多数研究中往往被忽略。同样的，这些影响在本研究中也并没有考虑。此外，文章将每天划分为288个时间段，每个时间段为5分钟。

文章采用了RMSE、MAE作为评价指标。模型训练过程中的损失函数曲线如下图所示。



本文提出的模型与其他方法效果的对比：

Table 2. Model Comparison

Method	RMSE	MAE
HA	1.0126	0.6924
ARIMA	1.2746	1.1289
MLP	1.1837	0.7228
SVR	1.0088	0.6916
LSTM	1.0048	0.6831
GCN	0.9879	0.6769
GCN-LSTM(Multi-Task)	0.9556	0.6688
T-GCN	0.9832	0.6728
MGLN	0.9535	0.6481

总结：文章提出了一种多任务学习机制，通过对于进、出站客流是直接图和间接图的分析与融合，通过简单的网络，实现了对于城市出租车需求的预测。